设施农业智能决策大模型关键技术与发展方向

冯在文[1]，许 多[1,2,3]，田 芳[1]，张红雨[1]，李万理[1]，彭 辉[1]，刘善梅[1]，刘汉尊[1]，金慧东[4]，黄 远[5]，吴颖丹[6]，龙 浩[1]，韩怡然[1,2,3]

（1. 华中农业大学信息学院，武汉 430070；2. 华中农业大学植物科学技术学院，武汉 430070；3. 华中农业大学数字农业研究院，武汉 430070；4. 澳大利亚联邦科学与工业研究组织数据研究所，堪培拉 2601；5. 华中农业大学园艺林学学院，武汉 430068；6. 湖北工业大学理学院，武汉 430068）

摘 要：在设施农业生产中，劳动密集的现象依然存在。如何提升设施农业的智能决策技术，进而提高生产力，是当前发展的核心问题。该研究聚焦于温室环境控制、作物生长过程的建模与预测、病虫害识别与预警、作物表型监测，以及系统与数据集成等设施农业智能决策关键应用场景，介绍了当前设施农业领域的相关智能化技术。系统且详细地剖析了视觉大模型、大语言模型、多模态大模型、具身智能大模型，以及大模型驱动的多智能体等大模型关键技术，并综合分析了现有大模型技术在设施农业中的应用潜力，论证了将大模型深度融入传统设施农业，将其应用于信息感知、生长模型搭建与精准决策等环节，能够有力推动设施农业决策体系向智能化迈进。分析了高质量数据集构建、传感器及优化集成的智能感知与实时监测技术研发、精准生长模型搭建，以及完善感知装备控制等设施农业智能决策大模型未来的发展方向。综述表明，在设施农业中引入大模型将成为极具前景的研究新范式。通过将大模型深度应用于农业智能感知、智能装备建设等领域，可以切实提升设施农业生产的精准化与智能化水平。

关键词：设施农业；具身智能；多模态大模型；大模型智能体；智能决策

doi：10.11975/j.issn.1002-6819.202411122

中图分类号：S126 **文献标志码**：A **文章编号**：1002-6819(2025)-13-0050-12

冯在文，许多，田芳，等. 设施农业智能决策大模型关键技术与发展方向[J]. 农业工程学报，2025，41(13)：50-61. doi: 10.11975/j.issn.1002-6819.202411122 http://www.tcsae.org

FENG Zaiwen, XU Duo, TIAN Fang, et al. Key technologies and development trends of intelligent decision-making large models for facility agriculture[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(13): 50-61. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202411122 http://www.tcsae.org

0 引 言

设施农业是增加农产品有效供给、保障食物安全的“菜篮子”工程。农业农村部关于印发《全国智慧农业行动计划（2024—2028 年）》的通知明确指出“加快推动人工智能大模型在农业农村科研、生产经营、管理服务等重点领域应用”。数字化、智能化是设施农业未来重要发展趋势。目前，制约中国设施农业智能决策的短板技术主要涉及以下三点：一是农业智能装备传感器落后，国内自主研发的传感器装置稳定性较差；二是农业模型的智能化决策精度低，难以发挥作用；三是缺乏智能化的设施农业体系技术[1]。设施农业智能决策技术的发展意义重大，首先，智能决策技术能够提高设施农业的生产效率和质量，在保障农产品供给、促产增收以及推进农业现代化方面发挥关键作用。其次，通过结合新兴技术赋能设施农业，能够更精准地监测和控制生产环境，实现个性化的生产管理，为农业生产提供更精准的指导，从而实现降本增效。因此，构建智能化的设施农业生产体系，实现精准化、低成本生产目标，是亟须解决的重大课题。

在解决设施农业智能决策短板技术、构建智能化生产体系的过程中，大模型凭借其强大的学习和处理能力，有望成为重要的技术支撑。大模型通过海量数据训练获得复杂的特征和模式，具有强大的泛化性以及智能涌现能力。大模型发展至今，已有诸多代表性成果。其中，用于自然语言处理的大语言模型（large language models，LLMs）[2]，通过对海量文本数据训练，学习到丰富的语言特征和语义知识，可应用于情感分析、文本问答等自然语言处理任务。视觉大模型用于图像分类、目标检测和分割等任务[3]，多模态大模型（multi-modal large models，MLMs）则在跨模态生成任务中发挥重要作用[4]。智能化农业设施的建设需紧密结合无人机、计算机视觉、大数据处理技术、云计算、大模型等多学科技术，实现农业全生产周期的精准决策与操作。大模型可为作物病虫害识别、智能育种、智慧养殖等多种农业下游任务提供智能化的决策支持。大模型具备多尺度、跨模态的特征提取能力，通过将学习到的通用表示迁移到不同任务和领域，可降低新场景开发成本[5]。

本文聚焦于温室环境控制、作物生长过程建模与预测、病虫害识别、作物表型监测与信息感知等关键应用场景，首先总结并分析当下设施农业的研究现状及其技

收稿日期：2024-11-15 修订日期：2025-04-22
基金项目：湖北省技术创新计划项目（2024BBB055）；湖北省科技厅援藏项目（2024EIA009）；云南省重大科技专项计划（202502AE090003）
作者简介：冯在文，博士，副教授，博士生导师，研究方向为 AI 大模型在农业信息中的应用。Email：Zaiwen.Feng@mail.hzau.edu.cn

术特征。其次，对 LLMs[2]、MLMs[4]、视觉大模型[6]、具身智能大模型[7] 以及大模型多智能体[8] 等关键技术进行了系统、详细的剖析。在此基础上，对现有大模型技术在设施农业领域的应用潜力进行全面评估。最后，分析当前大模型技术在设施农业应用中面临的挑战，并对其未来的发展方向进行前瞻性讨论。

1　设施农业决策场景概述

1.1　温室环境控制

物联网（internet of things，IoT）设备凭借其实时监测与数据采集能力，为农业数字化奠定了基础。其中，传感器感知技术是获取数据和信息的关键手段。传感器所采集的各类农情数据，首先经信息传递模块传输，随后经由后台解析技术处理，此过程中，抽象的温室环控信息被转换为数字信号，最终实现被测对象的测量[9]。传统温室环境控制将物联网技术和可编程逻辑控制器（programmable logic controller，PLC）结合，控制电机、水泵、风扇、补光灯等设备。近年来，世界各国的温室控制技术正向着完全自动化的方向发展。荷兰 Priva Compass 系统利用温差管理技术实现对花卉、果蔬等生长周期控制；美国 Agrify 公司通过预编程的 AgrifyInsights 规划作物生长或根据特定需求定制生产计划目标；以色列农业科技公司 Prospera 提出自主作物管理系统，使用 AI 算法实现对作物种植过程的自动化管理[10]。国内相关研究的侧重点多集中于预测温室内植物的生长状况，而依据计算结果实施自动化操作的探索相对较少，这在一定程度上反映了国内外在温室控制技术自动化领域的不同发展态势。

1.2　作物生长过程建模与预测

传统的作物建模大多通过机理建模来表征作物生长的过程。DSSAT[11]、AquaCrop[12]、WOFOST[13]、CERES[14] 以及 TOMSIM[15] 等是主流的作物生长模型。为了更好地模拟区域尺度作物的生长，耦合遥感技术的作物模型以及模块化的要素模型组合方式被应用于大区域的农业精准管理中[16-17]。尽管上述模型一定程度上能够预测、模拟作物的生长，但仍无法准确建模作物生长过程与多样环境变量间的非线性复杂关系。而 Transformer 模型在处理具有多变量特征的作物生长数据上展现了更优异性能，它能更有效地处理长距离依赖[18]。如 DeepCrop 采用了类似 Transformer 的编码器和解码器结构以及注意力机制，具备更强的适应性和泛化性[19]，可迁移并应用于各类作物。

1.3　病虫害识别与预警

传统的病虫害识别主要借助人工巡查管控[20]，这种方式存在识别不及时、精准度欠佳的缺陷。实际上，病虫害发生时，作物的病害发生部位通常会出现温度升高或降低的异常现象，这些异常温度变化可通过红外热成像仪准确地捕捉[21]。近年来，基于机器视觉的作物病虫害检测设备已在农业上初步应用，在一定程度上取代了传统的肉眼识别方式[22]。随着深度学习的发展，以卷积神经网络（convolutional neural network，CNN）为代表的深度学习模型也逐渐成为该领域的研究热点[23-24]。深度学习方法在识别不同背景下的多类害虫时，展现出了更强的鲁棒性。然而，在现阶段的病虫害识别任务中，依然存在一系列问题，如对病虫害细粒度特征的描述不够细致、内部相关性分析不够深入等[25]。

1.4　作物表型监测

作物在不同发育期的性状特征与产量、品质等生产指标息息相关。开展作物表型监测，以解析环境-基因型关系并预估产量，对推动设施农业智能化发展具有重要意义[26]。基于图像的作物表型检测，可直观呈现被测物体的形貌特征，进而了解作物的生长变化[27]。以设施番茄为例，对果实成熟度进行分类，不仅有助于实现果实生长状况的数字化监管，还能为种植过程中的无人化精准作业提供有力支持[27-28]。表型信息的准确、快速获取，可以弥补传统人工采集的主观性强、效率低下的弊端[29]。结合计算机视觉技术，农业机器人即使在复杂的温室环境中，也能监测果实的成熟度，有效避免不必要的经济损失[30]。

1.5　系统集成与数据集成

设施农业场景下的数据采集至关重要，设施农业智能决策离不开大量的高质量数据支撑，这些数据可用于训练和优化智能决策大模型，进而实现对设施农业生产过程的智能化管理和决策支持。传统的数据挖掘方法难以从多模态、异质异构的数据中获得可靠的知识与信息[31]。然而，农业资源信息缺乏高效、规范的整合。随着大量数据的不断积累，“数据孤岛”和“数据溢出”的问题日益凸显[32]。在农业领域，尤其是设施农业智能决策场景下，迫切需要建立规范化、标准化的数据存储与处理体系，以及支持数据跨平台、多协议的互操作机制。要实现基于数据驱动的智能化决策，关键在于达成软件系统与异构数据的高效集成与融合[33]。

2　设施农业智能决策大模型构建关键技术

2.1　融合大模型技术的设施农业智能决策体系建设

基于大模型的设施农业决策，在贯穿设施农业生产全周期的多个关键场景中发挥重要作用，大模型驱动的设施农业智能决策体系技术框架如图 1 所示。

作物生长过程建模与预测、作物表型监测、病虫害识别与预警以及温室环境控制这四类场景已积累了海量的数据与信息，这些数据和信息需要进一步借助系统集成与数据集成环节进行整合处理。结合各类大模型技术的优势来看，在上述场景中，LLMs[2] 可结合提示工程[34]，通过设计提示词，引导模型精准输出，侧重于农业数据分析、农事建议生成等任务。LLMs 耦合检索增强生成（retrieval-augmented generation，RAG）技术[35]，通过结合外部知识库，生成内容更准确可靠的文本。视觉大模型[6]可从作物图像模态数据中精准识别农作物、杂草等，监测作物生长，还可从图像模态数据中提取作物生长状态、果实成熟程度等语义信息并转化为文本，供研究人员分析决策。MLMs[4] 可通过多模态指令微调，针对图像、文本、语音等不同模态数据微调模型，从而使模型具备更为出色的多模态指令处理能力，以适用于设施农业具体应用场景。MLMs 多模态思维链可关联整合不同模态数

据，形成连贯的思维链，综合多方面信息做出更精准的决策。具身智能大模型[7]通过子目标分解，将复杂农业任务拆分为子目标逐步实现，如对温室环境控制复杂任务的分解；具身智能还可依据子目标规划动作序列，通过与农业机器人、传感器等设备进行深度集成，获取大量环境监测数据和作物生长数据，生成决策指令，与物理环境交互，并从环境反馈中进行学习和调整，不断增强决策能力。对于大模型驱动的多智能体系统[8]，其各智能体可依目标和环境信息决策行动。并且，智能体间以协作博弈的形式实现整体目标最优，各类智能体通过协作交互共享信息、协同工作，自适应地调整调控策略，为精准的环境调控决策提供有力支撑。

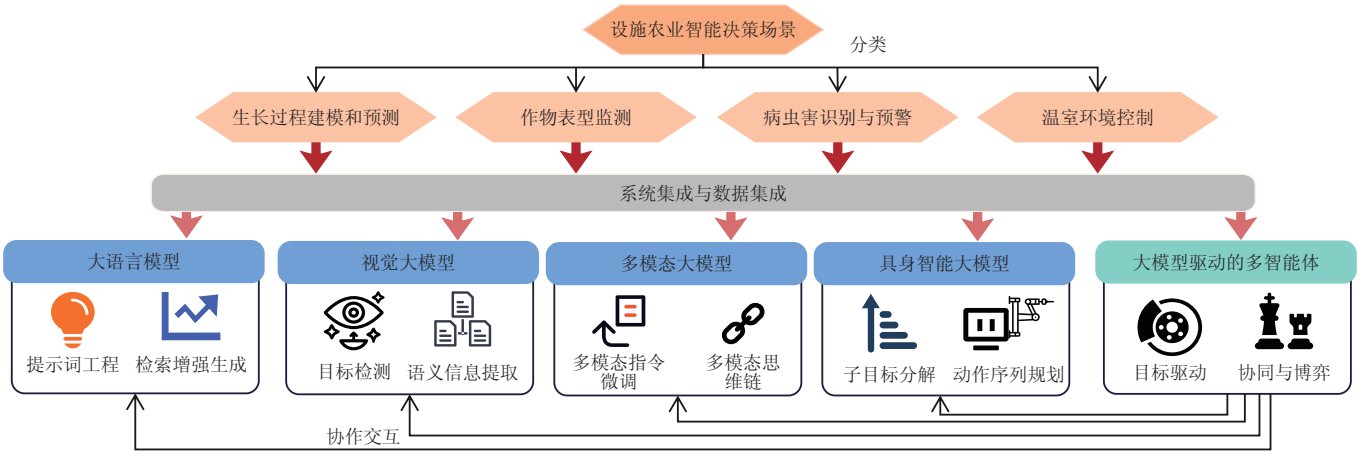


图 1 设施农业智能决策大模型（技术）框架

Fig.1 Technology framework of the intelligent decision-making large model for facility agriculture

2.2 大模型关键技术

2.2.1 大语言模型

早期的语言模型包括 BERT[36]等预训练模型。现阶段，LLMs 已成为通用人工智能系统中最为重要的构建模块。通过在广泛的数据集上进行训练，LLMs 的复杂性实现了指数级增长，适用于自然语言生成、自然语言理解、机器翻译、信息检索、农事诊断等多种下游任务[37-38]。借助微调、上下文学习和少样本学习等技术，LLMs 可针对特定任务进行定制化构建[39]。图 2 为基于 LLMs 的精准决策研究框架。

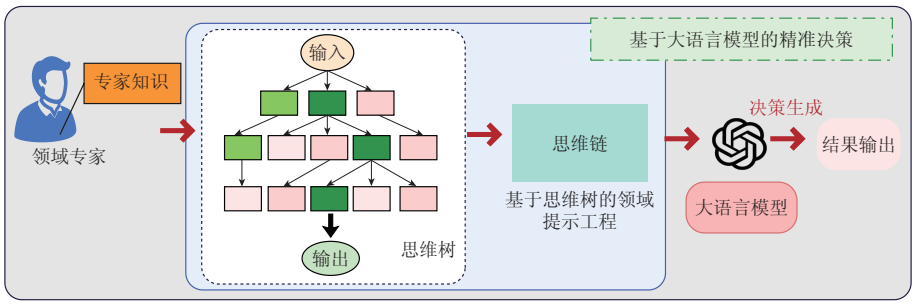


图 2 基于大语言模型的精准决策研究框架

Fig.2 Research framework for precision decision-making based on large language models (LLMs)

随着大模型在各个领域的广泛应用，许多研究指出，大模型生成的文本常常出现不遵循原文或与现实情况相悖的状况，这一现象被称为大模型“幻觉”问题[40]。对预训练大模型进行微调，以及采用 RAG 技术优化模型，可显著提高大模型的性能，并切实缓解大模型的幻觉问题[34]。PlanRAG 是一种检索增强生成技术，基于 PlanRAG 的 LLMs 在接收到输入的待处理任务数据时，首先对数据模式和获取的问题进行检查，以明确任务类型；随后，基于 PlanRAG 的 LLMs 生成相应的数据检索查询，进而在数据库执行查询操作；在此基础上，PlanRAG 会评估当前分析是否充分，如有需要则制定新的分析计划，并重复前述检索和生成步骤；最终，PlanRAG 生成相应的决策或输出结论[41]。

当下，LLMs 在农业领域的应用价值日益凸显。在农业生产过程中，会产生海量数据，这些数据涵盖了气象、土壤、作物生长状况等多个维度，运用传统的数据处理方式，难以对这些数据高效处理与利用。而 LLMs 强大的数据分析与处理能力，为农业决策带来新的契机。LLMs 可以从非结构化的农业文本数据中提取结构化信息，并对其进行不同格式间的转换以及在数据收集阶段识别数据中的潜在错误[42]。利用 LLMs 结合目标输入查询的作物产量预测方法[43]，通过设计一系列有针对性的提示词，指导 LLMs 整合和分析来自天气、土壤属性、历史产量和遥感的多源异构数据。相较于传统的机器学习模型，该方法在实体关系解析的上下文准确性和场景适应性方面具有显著优势。此外，LLMs 能够有效地实现与其他人工智能模型等外部系统耦合。以基于 LLMs 的农业文本信息提取系统为例[44]，该系统依托于 LLMs

和基于嵌入的检索技术（embedded-based retrieval，EBR），可自动从农业非结构化文本中提取实体、属性和相应的描述性术语，并进行匹配，从而生成易于计算机处理的结构化数据，该方法大幅减轻了涉农信息抽取的工作量。

提示工程是使用 LLMs 的核心技术，提示词指的是向大模型输入的指令或描述性文本，其目的是引导模型生成符合特定需求的输出[34]。LLMs 借助特定提示词完成广泛的文本生成任务，在此过程中，设计合理的提示词对于引导 LLMs 生成准确的输出结果至关重要[45]。思维链（chain of thought，CoT）方法在生成式任务的输入和输出之间融入了推理的中间步骤，以此增强 LLMs 的推理能力，且无需对模型参数进行更新[46]。思维树是思维链的扩展，该方法将推理过程表示为树状结构，而不仅仅是简单的线性链结构[46-47]。思维树由一系列嵌套提示词组成，构成了一个具有层次特性的推理流程。其中，树的根节点是问题陈述，由此分支出多个子步骤，且每个子步骤还可以进一步衍生分支，最终形成一个递归的树状结构。

作物生长过程建模与预测是大模型的典型应用场景[48]，借助作物模型，能够精准预测在当前温室环境条件下作物的生长态势，进而为后续的各项决策制定与实施提供科学且可靠的依据。传统作物模型存在一定的局限性。一方面，作物的生长是涉及众多因素的复杂过程，现有的作物模型难以对作物生长过程中的非线性复杂关系进行建模，因此这类模型在准确预测作物生长规律方面仍有待提高。另一方面，传统模型在应对不同植物种类和多变的生长条件时，表现出泛化性不足的缺陷。在现有的基于深度学习方法的作物生长建模中，CNN 通过卷积核提取局部特征，但无法充分捕捉序列不同位置之间的复杂关系，长短期记忆网络（long short-term memory，LSTM）在处理长距离特征时仍有局限[49]。相比之下，Transformer 模型[18] 利用注意力机制能有效捕捉全局上下文信息，具备更强的长距离依赖学习能力。在多头注意力结构中，每个头都应用独立的自注意力机制，使得模型可以在不同的表示子空间中学习相关信息。

作物从萌发到成熟收获的生理过程变化，本质上构成了一个以时间维度为核心的时间序列。这种时间依赖性的特质使得作物生长预测任务可以归属于时序预测（time series forecasting，TSF）的范畴。作物模型的构建涉及多尺度特征的学习，而基于自注意力机制的模型可契合任务需求，Transformer 可有效提取输入序列中各要素之间的复杂交互特征，对作物生长中气象、土壤、营养等多维度因素间的相互关系进行建模。例如，韩国文献 [19] 采用了类似 Transformer 编码器和解码器的结构，构建了水培甜椒过程模型 DeepCrop；该研究的系列试验表明，相较于现有作物机理模型，DeepCrop 模型具有更优异的适应性和泛化性。Transformer 的特征提取能力，在对作物生长过程中的气象、土壤、营养等多维度因素间相互作用进行建模时，发挥着关键的作用[50]。基于 Transformer 及相关改进模型的作物生长建模方法不断完善和创新，如 Informer[51]、PatchTST[52] 等模型在序列预测任务上取得了优异的性能。

2.2.2　视觉大模型

计算机视觉是人工智能的一个重要研究分支，通过视觉模型在大量的图像数据集上进行了预训练，使得模型具备理解图像内容和提取丰富的语义信息的能力[53]。计算机视觉涉及 4 个主要任务：1）图像分类，通过对图像特征和模式的识别，实现对图像样本的分类；2）对象检测，在图像中定位和识别不同物体的位置和类别，通常以图像框进行描述；3）语义分割，为图像的每个像素分配特定的语义类别，实现像素级别的语义理解和分类；4）实例分割，在语义分割的基础上进一步区分物体实例的边界，实现更精准的图像分割。计算机视觉已广泛应用于农业生产，特别是在设施农业领域，通过对农作物的特征进行精准识别和映射，从而实现环境感知、作物长势监测等。

目前，典型视觉大模型包括 ViT[54]、MAE[55] 及 SAM[6] 等。受自然语言处理技术的启发，ViT 模型采用了有监督的方式训练模型，将图像拆分为块（patch），并将图像块的线性嵌入序列作为 Transformer 的输入[54]。ViT 实现了从自然语言到视觉领域的跨域迁移，在图像分类、目标检测、语义分割等多个视觉任务上都取得了优异的表现。为实现采用自监督的方式训练视觉模型，提升模型性能，在 ViT 的基础上，MAE[55] 模型采用了高比例的掩码策略以及非对称的编码器解码器架构。其中，编码器只处理没有掩码标记的可见的图像块，而解码器则负责从编码表示和掩码标记中重建原始图像。这种设计解决了传统计算机视觉中 CNN 架构难以整合掩码标记的问题，并通过轻量级解码器大幅减少了计算量。MAE 等模型的提出代表了视觉大模型基本框架的形成。

SAM 模型通过为图像分割任务提供提示来实现任意目标的快速分割，具有强大的零样本和少样本的泛化能力，是代表性的视觉大模型[54-55]。SAM 可以根据点和边界框等输入提示对从未见过的图像执行对象分割，而无需事先了解对象类别[6]。该模型主体由图像编码器、提示编码器以及掩码解码器 3 部分构成。其中，图像编码器利用 ViT 将图像编码为特征向量；提示编码器使用多层感知器将提示编码为提示向量；而掩码编码器则通过另一个多层感知器将图像特征向量和提示向量拼接，生成每个像素的掩码概率。

SAM 模型作为全自动语义分割工具和半监督创建地面实况分割掩码的辅助工具，其在精准农业等领域的潜力仍需进一步探索。基于作物/杂草田间图像数据集（crop/weed field image dataset，CWFID）开展的 SAM 语义分割评估试验结果[56] 表明，SAM 模型的半自动分割模式可以显著加快地面实况注释过程，同时生成非常精准的地面实况蒙版。CWFID 数据集广泛用于作物和杂草辨识、单株表型研究等农业计算机视觉任务，数据集中的样本图像具有明显的前景和背景对比，这为全面了解 SAM 模型的性能奠定了基础。

在设施农业中，各种传感器采集了大量数据，内容涉及作物长势、养分水平等多个方面，且这些数据通常

以图像的形式呈现。因此，农业图像分割在信息感知任务中至关重要。利用视觉大模型，对受控环境作物图像进行分割，可以精确地识别出作物部分，进而实现对作物的监测、管理。农业图像通常具有以下特点：1）目标与背景对比度低，分割困难；2）农业背景复杂多样，有树叶、土壤；3）不均匀的光照和阴影会降低图像质量和清晰度；4）目标具有不同的形态，例如害虫和疾病。这些特点使得 SAM 很难适应农业图像分割的需求和特点，导致分割结果不准确或不完整。为增强 SAM 模型的适应性，可采用涵盖不同作物生长阶段、不同田间条件的作物图像，以及带有土壤和作物标签的数据对 SAM 模型进行微调[57]。通过这种方式，SAM 模型可以更好地适应不同的农业场景和条件，提升其在实际应用中的灵活性，增强应用效果。

在设施农业智能决策场景下，可采用融合视觉分割大模型的作物语义信息智能感知技术来提高决策的精准性和效率。通过提供掩模信息和植物目标检测模型提供的类别信息，少样本条件或零样本条件下，视觉大模型也可实现植物语义信息的高效智能提取[6]。基于注意力机制的果实位置匹配方法可有效解决现有果实匹配方法利用局部特征所导致的结果准确性较差的问题，具体而言，可采用自注意力[58]以及交叉注意力策略[59]，增强果实位置编码向量的匹配性能，并利用果实配对关系，精准计算果实三维坐标[60]。

2.2.3 多模态大模型

MLMs[61]是将 LLMs 的自然语言处理能力以及其他模态（例如视觉、音频等）数据的理解与生成能力相结合的模型。MLMs 的通用架构通常包括模态编码器、LLMs 和适配器模块这 3 个关键组件[61]。其中，模态编码器负责对输入的原始模态数据（如图像、视频、音频）进行预处理，并将其转换为适合进一步处理的低维嵌入。这一过程通常涉及使用预训练的视觉或音频模型（如 ResNet、CLIP 等）。LLMs 是 MLMs 的核心部分，通常基于 Transformer 架构，如 BERT 或 GPT 系列模型。适配器模块是 MLMs 中的关键部分，是连接模态编码器和 LLMs 的桥梁。适配器的主要任务是确保来自不同模态的数据在同一空间中对齐，以便 LLMs 可以有效地利用这些多模态信息进行推理。

MLMs 包含以下基础技术：1）多模态指令微调（multimodal instruction tuning，M-IT）[62]：指令指的是对任务的描述，多模态指令数据的基本形式可以概括为三元组（指令，多模态输入，回答），M-IT 是一种通过指令格式的数据来微调预训练 MLMs 的技术。通过该技术，MLMs 可跟随新的指令泛化到未处理过的任务上，提升零样本处理性能。2）多模态上下文学习（multimodal in-context learning，M-ICL）[63]有效地利用了 LLMs 的少样本学习能力。通过给定少量样例作为输入，激发模型潜在的能力并规范化模型的输出。3）多模态思维链（multimodal chain of thought，M-CoT）[46]适用于需要分步推理的多模态任务，其思想是通过清晰地呈现逐步推理的过程，并给出中间的推理步骤，进而获得多模态任务的答案。相较于直接输出答案的方式，M-CoT 在处理较为复杂的推理任务时，展现出更优异的性能。

在设施农业领域中，每年因病害造成的作物损失占总产量的 10%~30%[64]。因此，迫切需要找到快速、精准的病虫害防治手段。当前，图像处理、深度学习等技术已经在作物病虫害诊断中广泛应用[65-66]，但单纯依靠图像模态数据进行病害表示学习存在一定局限性。首先，图像模态数据无法全面覆盖病害表现的所有特征，例如病害的生理变化、环境因素以及植物的生长状态等[67]。其次，当前模型主要针对低级图像特征如颜色、纹理和形状等学习，上述特征虽然对基本的病害识别有帮助，却无法深入理解病害的潜在原因和机制，这导致模型的识别决策缺乏透明度，难以为农民和农业专家提供有效的解释和指导[21]。将文本、图像等多种模态的农业知识进行融合，并基于多种异构信息提供智能知识服务的 MLMs 不断涌现。例如 ITLMLP 融合了图像、文本和标签 3 种输入方式，并在模型中引入了 CLIP 和 SimCLR 的部分结构，在黄瓜病虫害识别任务中展现出应用潜力[68]。ITLMLP 通过对比学习方法，融合图像、文本信息以及标签信息，在少样本条件下进行学习。将 ITLMLP 与 CLIP、SimCLR 和 SLIP 模型在病虫害识别任务上的结果进行对比发现，ITLMLP 在多项黄瓜病害识别指标上表现更为出色，且在其他植物病害识别任务中具有良好性能，显示出较强的泛化能力[68]。基于 YOLOPC 的农业图像 GPT 辅助诊断方法[69]，通过提取农业边缘的图像特征并将其转化为文本，用于植物病虫害的实时诊断。具体来说，该研究将待检测的图像（例如 RGB 图像）输入到经过多次不同训练的 YOLO 模型中，以获取输出结果。输出结果通常包括多个识别类别及其对应的识别框。上述输出结果紧接着被映射为自然语言，使得 GPT-4 能够以可读的方式理解识别信息。

2.2.4 具身智能大模型

具身智能大模型的核心在于智能体能够在数字空间以及物理世界中灵活地应对复杂多变的环境。在过去几十年的研究中，离身智能方法侧重于基于大量的数据和算法，在虚拟环境中对数据进行学习和分析，然后将学习到的知识应用到不同的场景中。例如，传统的机器学习算法在图像识别任务中，通过对大量标注图像的学习，训练模型识别新的图像，离身智能主要关注数据的处理和模型的训练，而不依赖于与现实环境的直接交互。而具身智能方法则更强调与环境的交互。具身智能认为智能不仅仅是进行抽象的计算和推理，还需要通过物理实体与环境的互动来获取感知信息，从而更好地理解和适应环境。

人工智能技术和机器人技术的快速发展为具身智能带来了研究机遇。LLMs 在多类自然语言处理任务中取得了显著进展，能够处理复杂的句法和语义，并在理解任务指令和文本内容时表现出色[70]，上述特征使得 LLMs 能够在零样本、少样本场景中更好地完成任务。视觉大模型具备强大的图像理解能力，在各种领域的图像数据分割中都能取得良好的分割效果[71]，为决策和行动提供

了视觉依据。MLMs 将视觉等模态的数据与语言模型深度融合[72]，极大地增强了模型在视觉-语言方面的交互与理解能力。在应对复杂环境时，多模态数据融合是一种不可或缺的技术手段，它能够显著提升感知的全面性、鲁棒性与准确性，为复杂环境下的高效决策和规划提供了关键支撑。上述大模型相关技术的蓬勃发展，为具身智能的研究提供了丰富的技术手段和广阔的发展空间。

在机器人技术的相关研究中，赋予机器人感知、学习和交互能力已成为领域内的研究热点[73]。尽管目前在提升机器人解读人类命令以及自主规划任务能力方面已取得了一定进展，如通过创建各类任务规划语言推动动作序列的自动生成[74]，或采用将人类指令转换为结构化任务描述等举措[75]，但这些方法的泛化能力和自适应性仍存在不足。

因此，大模型与机器人技术的结合，避免了高昂的用户偏好数据收集成本和模型训练成本，为具身智能在个性化场景中的应用奠定了基础。LLMs 可使得机器人理解复杂语言指令，将语言命令映射到具体动作序列，并在执行中实时感知环境变化、动态调整行为[74]。多模态模型打破了语言与视觉等模态的壁垒，使具身智能系统拥有多感官的感知和决策能力，如在农机自动驾驶中应用多模态模型，可学习不同感知模态间的关联和互补关系，获得对环境更全面准确的理解，提高决策的可靠性[76]。

具身智能包括具身感知、具身交互、具身智能体以及虚拟到现实的迁移 4 大关键要素[7]。在具身任务中，智能体需要理解人类指令的意图，主动探索环境，感知来自虚拟和物理世界的多模态信息，并执行相应的操作以完成复杂任务。在设施农业温室环境控制任务中，不仅需要完成数据的接收、处理、反馈流程，并据此做出决策，还需要与物理环境进行交互，从而实现实时的环境调整和管理。面向设施农业智能决策的具身智能大模型架构如图 3 所示。

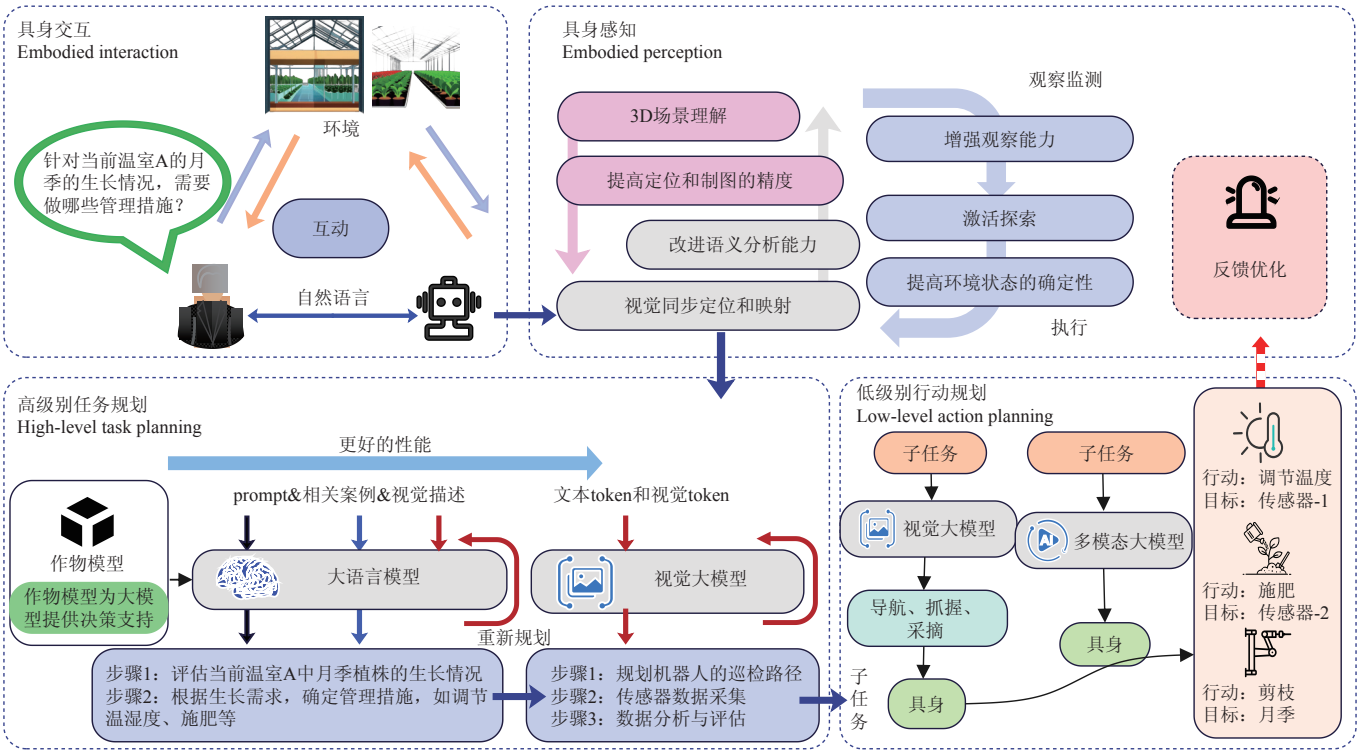


图 3　面向设施农业决策的具身智能大模型架构

Fig.3　Embodied intelligence architecture for facility agriculture decision-making

具身智能大模型包括具身交互、具身感知、高级别任务规划以及低级别行动规划 4 部分。如图 3 所示，具身智能需要从自然语言中提取任务目标，智能体需要与人类或其他智能体进行多模态的交互和交流，以获取指令和反馈。机器人是典型的具身形式。机器人可以借助机械臂、车轮等实现精细动作控制和大范围的空间移动，从而完成果实采摘、智能巡检等任务。机器人所具备的这种通过机械结构实现动作控制与空间移动的能力是具身智能得以实现的物理基础。

具身感知需要智能体在物理世界中移动并且能够与环境进行交互（图 3）。具身智能的感知能力不仅仅局限于识别图像中的物体，还需要理解场景中的三维空间关系，并基于这种视觉感知信息预测和执行复杂的交互任务。主动视觉感知、3D 视觉定位、视觉语言导航是具身智能的核心技术。主动视觉感知能力使智能体可以主动控制视角、焦点等参数，从而获取更丰富的场景信息，支持对复杂环境的深入理解。3D 视觉定位则提供了环境的三维空间表征，为智能体的导航和操作提供基础。视觉语言导航则融合了视觉感知和自然语言理解，使智能体能够通过人机交互完成复杂的导航和操作任务。

从规划的维度来划分，具身智能可分为高层次任务规划和低层次任务规划。高层次任务规划是将抽象复杂的目标分解为可执行的子任务，需要智能体具有对任务、环境的深入理解和推理能力（图 3）。在设施农业智能

决策体系中，用户的需求以及生产的目标引导决策的生成，而作物模型为这些决策提供科学依据。对于具身智能系统而言，作物模型属于其内部知识库的一部分。作物模型可以预测作物生长趋势、诊断产量瓶颈、评估管理策略等，为高层次的具身任务规划提供重要依据。低层次行动规划是具身智能体实现虚拟到现实的关键环节（图 3）。通过实时感知反馈不断调整行动策略，使得具身智能体能够适应设施农业生产环境，并通过调用多种传感器获取环境信息，同时控制设施农业智能机器人等，最终完成生产作业任务。

具身智能的规划控制层级可分为需求级、任务级、规划级以及动作级[77]。其中，需求级旨在精准理解用户需求，并将其细致拆解为具体任务，这一过程属于高层次任务规划的重要范畴，其核心在于明确整体目标与方向，为后续的任务执行奠定基础。如 Text2Motion[78]、PaLM-E[79] 等方法通过大模型实现此过程。任务级指的是具身智能大模型完成具体的任务的过程，这既涉及预定义技能的低层次规划，也涵盖了大模型处理子任务的高层次规划内容，是高低层次任务规划的衔接环节[77]。

规划级指的是具身智能针对具体任务规划未来动作，为低层次任务规划提供行动框架与目标，是高低层次任务规划的过渡环节。以 VoxPoser[80] 为例，它巧妙利用了 LLMs 的优势。LLMs 善于依据自由形式的语言指令来推断功能和约束条件，VoxPoser[80] 让 LLMs 与视觉大模型进行交互，进而构建出组合地图。这一过程是针对给定的操纵任务（即具体任务）来规划未来动作。所构建的价值地图被应用于基于模型的计划框架，能够从零开始合成闭环机器人轨迹。这为后续机器人在实际环境中执行任务明确了方向、确立了目标，在高低层次任务规划之间起到了承上启下的过渡作用。动作级指的是具身智能输出直接控制机器人运动的动作序列，属于低层次任务规划，如 RoboFlamingo[81]、Prompt2Walk[82] 等研究致力于将任务规划有效转化为实际动作，以推动机器人完成具体任务。

强化学习[83] 为具身智能提供了一种有效的学习机制，在这一机制下，智能体在与环境的交互进程中，能够依据环境反馈的奖励信号，调整自身的行为策略，旨在实现长期累积奖励的最大化。尽管当前面向设施农业的具身智能相关研究尚处于探索阶段，但面向温室环境自动化控制的强化学习技术已渐趋成熟。例如，基于深度确定性策略梯度（DDPG）[83] 的强化学习方法被应用于温室气候控制领域，该方法通过与环境的交互学习最优控制策略，展现了强化学习在温室环境控制中的应用潜力。Trans-Farmer[84] 在强化学习温室控制的基础上，采用注意力机制学习环境变量之间复杂的关系，其编码器-解码器结构能够将环境变量转换为相应的控制变量，并且已成功在温室微控制器上完成部署。强化学习框架的引入，有效增强了温室种植策略的泛化性与鲁棒性[85]。GreenLight-Gym[86] 是首个专为温室模型上训练和评估强化学习算法而设计的开源环境，该开源环境进一步推动了基于强化学习的温室环境控制的研究。

2.2.5 大模型驱动的多智能体系统

设施农业智能决策涉及多个下游任务，各下游任务可结合不同类型的大模型技术，如采用视觉大模型用于信息感知与监测、利用 LLMs 实现精准决策、使用 MLMs 用于病虫害识别以及采用 Transformer 架构构建具有更强泛化能力的生长模型。在具体下游任务应用时，需要考虑如何有效整合各类大模型技术，以更好地应对复杂多变的农业环境和生产需求，实现智能体与环境的有效交互。

多智能体系统（multi-agent systems，MAS）由多个可交互的人工智能智能体（AI agent）构成，这些智能体是能够独立运行的实体，可以根据环境变化自行做出决策和采取行动[8]。MAS 的核心是 AI agent。通过设计任务流程和利用可用工具，能够自主代表用户或其他系统执行任务。AI Agent 与传统 LLM 的区别在于使用工具和设计行动计划的能力。MAS 在复杂场景下具有显著优势：1）灵活性，MAS 能够通过添加、删除或调整智能体适应不同环境的变化，使得系统能够迅速响应新的挑战和需求；2）可扩展性，多个智能体之间的协作可以形成更大的共享信息池，协作的形式使得 MAS 能够解决比单一智能体系统更复杂的问题和任务，从而提高整体效率；3）领域专业化，在 MAS 中，每个智能体可以专注于特定领域获得任务的专业知识，而不必由单一智能体承担所有任务。

在温室环境控制场景下，利用 MAS 技术，可以有效地优化温室环境条件，对作物的长势进行调控。具体来说，首先，环境监测智能体实时监测温度、湿度和光照等环境因素，通过传感器收集数据，并及时将环境的变化反馈给任务规划智能体。其次，作物生长智能体根据环境监测智能体提供的数据，通过调用相关作物的生长模型，预测植物的生长趋势，并根据上述预测结果调整灌溉、施肥等农事管理策略。再次，病虫害监测智能体负责监测和识别病虫害状况，评估其对作物生长的影响，并将相关数据反馈给任务规划智能体。任务规划智能体在温室环境控制中具有核心作用，该智能体负责汇集来自各个智能体的反馈信息，这些信息涵盖了环境数据、生长预测和病虫害信息等多个方面。通过反馈信息的综合处理，任务规划智能体制定优化温室环境的决策方案。最后，环境控制智能体根据任务规划智能体生成的决策，执行具体的环境调整操作。通过上述的多智能体交互方式，MAS 使得设施农业的温室环境控制具备场景迁移性，能够灵活适应不同环境和需求，为农业生产提供更高效的管理方案。

3 构建设施农业智能决策大模型面临的主要挑战

当前设施农业智能决策大模型的构建仍面临多种挑战：

1）设施农业数据通常呈现出多源异构的特征，不同来源的数据在格式、结构和标准上存在显著差异，且数据之间缺乏有效的关联机制，这使得“数据孤岛”的问题尤为严重，加剧了数据整合和汇聚的困难。此外，数据量普遍稀缺的问题仍然存在。以病虫害识别任务为例，获取大量高质量标注数据的难度高，导致数据标注成本

上升。对于无人机图像、卫星图像等图像模态数据，可采用通用的数据增强方法[87]，如添加高斯和伽马噪声、使用自适应直方图均衡化等措施。对于文本模态数据，可通过构建外部知识库来增强大模型的泛化能力，如利用领域知识图谱为图像特征学习和病害识别提供外部指导。对于传感器数据，可通过提取数值特征用于后续与其他模态的特征进行融合。对于遥感数据，栅格化的高光谱图像（HSI）以像素网格的形式呈现数据，而机载激光雷达（LiDAR）则生成密集的三维点云。因此，需考虑多模态、多分辨率数据的特征融合。

2）在农业场景中，传感器往往暴露在不同的环境中，且应用于多样的农业条件。在使用过程中，由于环境变化、设备老化或校准问题，传感器的数据输出可能逐渐偏离真实值，这种传感器漂移现象在农业应用中极为常见。传感器漂移所导致的错误数据不仅会引发错误决策，还严重影响农业生产的效率。此外，LLM 与 IoT 的集成应用面临着诸多难题。LLM 所需的大量计算能力和能耗，会对物联网设备有限的资源带来压力。实时处理数据的需求也会引发延迟问题，尤其是在协调平衡边缘技术和云计算资源的过程中，如何确保数据的及时处理较为棘手[88]。同时，部署和维护的可扩展性，以及不同物联网平台间的兼容和集成增加了集成技术的难度。

3）不同模态数据的融合在病害识别任务中尤为重要，因为病害识别的结果直接影响后续的防治策略、药物喷洒和农业管理决策。现有方法不仅忽略了除图像特征之外的其他模态数据在病害识别中的作用与价值，还未能充分运用已有的领域知识，致使识别结果的可信度和可解释性欠佳。这些信息的缺失可能导致单一模态大模型在处理复杂任务时的局限性，无法准确获取和理解病害的整体特征。因此，整合其他模态数据为病害的分析提供更为全面的视角尤为重要。

4）面对多样化的生产需求，农业环境复杂多变，大模型需要具备良好的适应性，以应对不同作物生长阶段、气候变化和病虫害的挑战。在解决具体问题时，尤其是在设施农业数据覆盖不全面和质量参差不齐的情况下，大模型的适应能力亟待提升。因此，确保数据的准确性和完整性，构建高质量的农业数据集是解决这一问题的关键。

5）构建设施农业场景下的智能决策大模型需突破大模型“幻觉”问题以及领域知识缺失的双重挑战[40]。在开展垂直领域应用中，可结合 RAG、知识图谱和 MAS 等技术来提升模型的决策的精准性。RAG 技术利用外部知识库检索来增强大模型的生成能力，以缓解模型在生成决策时的幻觉现象。知识图谱技术可用于整合多源异构的农业数据，构建领域内规范的知识体系。MAS 可用于实现设施农业复杂场景中的多任务协同决策。通过将不同的农业任务配给不同的专业智能体，实现任务的并行处理和协同优化。

4　总结与展望

随着大模型在设施农业各个场景的决策任务中取得显著成就，大模型已成为人工智能领域的科技里程碑。大模型可通过捕捉大规模数据中的复杂机理和规律模式，进而充分地理解问题，输出推理结论。现阶段，将大模型引入设施农业决策领域，是一种极具前景的新范式，可推动行业的革新和农业研究的全新发展。未来设施农业智能决策关键技术可围绕以下方面开展：

1）建立高质量的设施农业数据集。农业进入大数据时代，设施农业的智能决策大模型的搭建需要建立在高质量大数据驱动的基础之上。设施农业涉及众多环节，数据来源丰富多样。高质量数据集的构建应涵盖设施农业生产过程中的各类型数据。其次，数据的准确性与可靠性至关重要。为确保数据质量，要建立严格的数据采集标准与校准机制。

2）发展基于大模型的智能感知与实时监测技术，提高农业数据准确性。在农业生产中，监测起着至关重要的作用，是实现精准农业的基础。针对传感器的数据漂移问题，搭建实时监测系统以持续追踪传感器性能。一旦监测到数据漂移情况，需及时对模型输入进行调整或对传感器加以校准。软计算方法借助模糊逻辑、神经网络和遗传算法等技术，实现对传感器的检测和校准。信息的感知与决策往往依托于硬件设备，持续推动农业硬件设备的技术创新和应用，将为设施农业的智能化转型提供强大的技术支撑，为农业的可持续发展注入新的动力。在资源受限的物联网环境中，优化大模型与 IoT 的集成，可减少大模型的训练、微调和推理的计算和内存占用。通过在边缘云设备上对大模型进行优化部署，可减少推理延迟并提高物联网应用中大模型的实时处理能力，并且对 LLMs 能耗实现优化。强化相关标准或协议的建设，确保 LLMs 与多种物联网平台和设备的无缝集成、互操作性以及可移植性。

3）构建精准生长模型。为构建基于时序大模型的作物生长模型，需要整合多种技术手段，以实现对具有异质异构特性的作物-环境监测数据的有效采集。可通过融合遥感、地面传感等多种智能感知装备，构建标准化作物生长数据集。同时，利用 Transformer 等人工智能技术，发掘作物生长时间、环境因子、长势之间的复杂关联。生长模型可模拟不同种植方案下作物的生长表现，帮助选择最佳的品种搭配、种植时间、种植密度等，提高整体产量和资源利用效率。未来，应发展多模态的作物模型，使其能够有效整合多种模态的数据，为决策提供更准确、可靠的依据。

4）优化感知装备控制，建立数据标准化机制。将遥感、地面传感等感知装备与边缘计算设备进行深度融合，实现对感知装备的智能控制。通过在边缘侧部署轻量级的控制算法，能够根据实时监测数据快速调整设备参数，如调节温湿度传感器的采样频率、优化图像捕获参数等，从而提升整体感知系统的效率与稳定性。在将感知数据传输至大模型进行分析前，需要在边缘侧进行初步的数据预处理。如滤波、归一化、特征提取等操作，以降低数据冗余，提高传输和分析的效率。同时，针对不同传感设备的异构数据，还需要进行统一的数据格式转换和

语义注释，确保大模型能够高效理解和利用。将作物表型识别模型嵌入农业芯片，使其能够在边缘设备上实时运行，进而缓解数据传输延迟，减少对云端服务器的依赖，提高响应速度。

综上所述，智能决策是农业发展的核心驱动力，其本质在于充分挖掘和利用多源异构数据，释放数据潜在价值，从而推动农业智能化发展。为增强设施农业智能决策体系水平，应在设施农业的各类应用场景中深度融合大模型技术。具体而言，可从智能感知、作物表型监测、生长模型构建、病虫害识别与预警、温室环境控制等多个应用场景出发，推动设施农业朝着智能化、体系化、精准化方向迈进。

[参 考 文 献]

[1] 赵春江. 智慧农业发展现状及战略目标研究[J]. 智慧农业，2019，1(1)：1-7.
ZHAO Chunjiang. Research on the development status and strategic objectives of smart agriculture[J]. Smart Agriculture, 2019, 1(1): 1-7. (in Chinese with English abstract)

[2] SUFI F. Generative pre-trained transformer(GPT) in research: A systematic review on data augmentation[J]. Information, 2024, 15(2): 99.

[3] BAI Y, GENG X, MANGALAM K, et al. Sequential modeling enables scalable learning for large vision models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 22861-22872.

[4] LI B, GE Y, GE Y, et al. Seed-bench: benchmarking multimodal large language models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 13299-13308.

[5] OLIVEIRA R C, SILVA R D S. Artificial intelligence in agriculture: Benefits, challenges, and trends[J]. Applied Sciences, 2023, 13(13): 7405.

[6] SUN W, LIU Z, ZHANG Y, et al. An alternative to wsss? An empirical study of the segment anything model (sam) on weakly-supervised semantic segmentation problems[EB/OL]. [2023-06-18]. https://doi.org/10.48550/arXiv.2305.01586.

[7] LIU Y, CHEN W, BAI Y, et al. Aligning cyber space with physical world: A comprehensive survey on embodied AI[EB/OL]. [2024-08-26]. https://doi.org/10.48550/arXiv.2407.06886.

[8] GUO T, CHEN X, WANG Y, et al. Large language model based multi-agents: A survey of progress and challenges[EB/OL]. [2025-03-22]. https://doi.org/10.48550/arXiv.2503.17726.

[9] 岳学军，蔡雨霖，王林惠，等. 农情信息智能感知及解析的研究进展[J]. 华南农业大学学报，2020，41(6)：14-28.
YUE Xuejun, CAI Yulin, WANG Linhui, et al. Research progress on intelligent perception and analysis of agricultural information[J]. Journal of South China Agricultural University, 2020, 41(6): 14-28. (in Chinese with English abstract)

[10] 王方媛. 国际现代设施农业企业项目案例[EB/OL]. [2025-01-01]. https://www.istis.sh.cn/cms/news/article/55/27310.

[11] VANUYTRECHT E, RAES D, STEDUTO P, et al. AquaCrop: FAO's crop water productivity and yield response model[J]. Environmental Modelling & Software, 2014, 62: 351-360.

[12] DE W A, BOOGAARD H, FUMAGALLI D, et al. 25 years of the WOFOST cropping systems model[J]. Agricultural Systems, 2019, 168: 154-167.

[13] RITCHIE J T, NESMITH D S. Temperature and crop development[J]. Modeling plant and soil systems, 1991, 31: 5-29.

[14] HEUVELINK E. Evaluation of a dynamic simulation model for tomato crop growth and development[J]. Annals of Botany, 1999, 83(4): 413-422.

[15] HOLZWORTH D, HUTH N I, FAINGES J, et al. APSIM next generation: Overcoming challenges in modernising a farming systems model[J]. Environmental Modelling & Software, 2018, 103: 43-51.

[16] NASIRAHMADI A, HENSEL O. Toward the next generation of digitalization in agriculture based on digital twin paradigm[J]. Sensors, 2022, 22(2): 498.

[17] ZHOU S, WANG L, LIU J, et al. An ENKF-LSTM assimilation algorithm for crop growth model[EB/OL]. [2024-03-06]. https://doi.org/10.48550/arXiv.2403.03406.

[18] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems, NewYork: NIPS, 2017: 6000-6010.

[19] MOON T, KIM D, KWON S, et al. Process-based crop modeling for high applicability with attention mechanism and multitask decoders[J]. Plant Phenomics, 2023, 5: 0035.

[20] 史东旭，高德民，薛卫，等. 基于物联网和大数据驱动的农业病虫害监测技术[J]. 南京农业大学学报，2019，42(5)：967-974.
SHI Dongxu, GAO Demin, XUE Wei, et al. Research on agricultural disease and pest monitoring technology based on internet of things and big data[J]. Journal of Nanjing Agricultural University, 2019, 42(5): 967-974. (in Chinese with English abstract)

[21] ZHOU J, LI J, WANG C, et al. Crop disease identification and interpretation method based on multimodal deep learning[J]. Computers and Electronics in Agriculture, 2021, 189: 106408.

[22] 苑严伟，白圣贺，牛康，等. 智能化农业物料输送技术进展与趋势[J]. 农业工程学报，2022，38(7)：78-90.
YUAN Yanwei, BAI Shenghe, NIU Kang, et al. Progress and trend of intelligent agricultural material conveying technologies[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(7): 78-90. (in Chinese with English abstract)

[23] KUTE R S, VYAS V, ANUSE A. Component-based face recognition under transfer learning for forensic applications[J]. Information Sciences, 2019, 476: 176-191.

[24] LIAO W X, HE P, HAO J, et al. Automatic identification of breast ultrasound image based on supervised block-based region segmentation algorithm and features combination migration deep learning model[J]. IEEE Journal of Biomedical and Health Informatics, 2019, 24(4): 984-993.

[25] LIU J, WANG X. Plant diseases and pests detection based on deep learning: a review[J]. Plant Methods, 2021, 17: 1-18.

[26] 朱逢乐，严霜，孙霖，等. 基于深度学习多源数据融合的生菜表型参数估算方法[J]. 农业工程学报，2022，38(9)：

195-204.
ZHU Fengle, YAN Shuang, SUN Lin, et al. Estimation method of lettuce phenotypic parameters using deep learning multi-source data fusion[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(9): 195-204. (in Chinese with English abstract)

[27] 王传宇，郭新宇，杜建军，等. 基于时间序列图像的玉米植株干旱胁迫表型检测方法[J]. 农业工程学报，2016，32(21)：189-195.
WANG Chuanyu, GUO Xinyu, DU Jianjun, et al. Maize plant drought stress phenotype testing method based on time-series images[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2016, 32(21): 189-195. (in Chinese with English abstract)

[28] CAMARRETTA N, HARRISON P A, LUCIEER A, et al. From drones to phenotype: Using UAV-LIDAR to detect species and provenance variation in tree productivity andstructure[J]. Remote Sensing, 2020, 12(19): 3184-3201.

[29] ElSAPPAH H A, QI S, A. SOAUD S, et al. Natural resistance of tomato plants to tomato yellow leaf curl virus[J]. Frontiers in Plant Science, 2022, 13: 1081549.

[30] 董适，赵国瑞，苟豪，等. 基于改进 RT-Detr 的黄瓜果实选择性采摘识别方法[J]. 农业工程学报，2025，41(1)：212-220.
DONG Shi, ZHAO Guorui, GOU Hao, et al. Identifying cucumber fruits during selective picking using improved RT-Detr[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(1): 212-220. (in Chinese with English abstract)

[31] GOLDSTEIN A, FINK L, RAVID G. A cloud-based framework for agricultural data integration: A top-down-bottom-up approach[J]. IEEE Access, 2022, 10: 88527-88537.

[32] BAZZI C L, JASSE E P, GRAZIANO M P S, et al. Agdatabox api: Integration of data and software in precision agriculture[J]. SoftwareX, 2019, 10: 100327.

[33] LI J, XU M, XIANG L, et al. Large language models and foundation models in smart agriculture: Basics, opportunities, and challenges [EB/OL]. [2024-03-17]. https://doi.org/10.48550/arXiv.2308.06668.

[34] MARVIN G, HELLEN N, JINGO D, et al. Prompt engineering in large language models[C]//International conference on data intelligence and cognitive informatics. Singapore: Springer Nature Singapore, 2023: 387-402.

[35] TING W, NA W, YUNPENG C U I, et al. Agricultural technology knowledge intelligent question-answering system based on large language model[J]. Smart Agriculture, 2023, 5(4): 105.

[36] DEVLIN J, CHANG M W, LEE K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[EB/OL]. [2019-05-24]. https://doi.org/10.48550/arXiv.1810.04805.

[37] REZAYI S, LIU Z, WU Z, et al. AgriBERT: Knowledge-infused agricultural language models for matching food and nutrition[C]//Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence(IJCAI). California: Morgan Kaufmann, 2022: 5150-5156.

[38] LIU Z, HE X, LIU L, et al. Context matters: A strategy to pre-train language model for science education[C]//International conference on artificial intelligence in education. Cham: Springer Nature Switzerland, 2023: 666-674.

[39] DU Y, WATKINS O, WANG Z, et al. Guiding pretraining in reinforcement learning with large language models[C]// International Conference on Machine Learning. Hangzhou: PMLR, 2023: 8657-8677.

[40] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions[J]. ACM Transactions on Information Systems, 2025, 43(2): 1-55.

[41] LEE M, AN S, KIM M S. PlanRAG: A plan-then-retrieval augmented generation for generative large language models as decision makers[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Mexico: Association for Computational Linguistics, 2024: 6537-6555.

[42] LU G, LI S, MAI G, et al. Agi for agriculture[EB/OL]. [2023-04-12]. https://doi.org/10.48550/arXiv.2304.06136.

[43] KUSKA M T, WAHABZADA M, PAULUS S. AI for crop production-where can large language models(LLMs) provide substantial value?[J]. Computers and Electronics in Agriculture, 2024, 221: 108924.

[44] PENG R, LIU K, YANG P, et al. Embedding-based retrieval with llm for effective agriculture information extracting from unstructured data[EB/OL]. [2023-08-06]. https://doi.org/10.48550/arXiv.2308.03107.

[45] OPPENLAENDER J. A taxonomy of prompt modifiers for text-to-image generation[J]. Behaviour & Information Technology, 2024, 43(15): 3763-3776.

[46] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 24824-24837.

[47] BESTA M, BLACH N, KUBICEK A, et al. Graph of thoughts: Solving elaborate problems with large language models[C]// Proceedings of the AAAI Conference on Artificial Intelligence. Washington: AAAI, 2024: 17682-17690.

[48] ZHU H, QIN S, SU M, et al. Harnessing large vision and language models in agriculture: A review[EB/OL]. [2024-07-29]. https://doi.org/10.48550/arXiv.2407.19679.

[49] WANG Y, LIU M, BAO Z, et al. Short-term load forecasting with multi-source data using gated recurrent unit neural networks[J]. Energies, 2018, 11: 1138.

[50] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International conference on machine learning. New York: PMLR, 2017: 1126-1135.

[51] ZHOU H, ZHANG S, PENG J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. New York: IEEE, 2021: 11106-11115.

[52] HUANG X, TANG J, SHEN Y. Long time series of ocean wave prediction based on PatchTST model[J]. Ocean Engineering, 2024, 301: 117572.

[53] HE K, CHEN X, XIE S, et al. Masked autoencoders are scalable vision learners[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition.

Piscataway, New Jersey: IEEE, 2022: 16000-16009.
[54] KIRILLOV A, MINTUN E, RAVI N, et al. Segment anything[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway, New Jersey: IEEE, 2023: 4015-4026.
[55] LIU P, YUAN W, FU J, et al. Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing[J]. ACM Computing Surveys, 2023, 55(9): 1-35.
[56] CARRARO A, SOZZI M, MARINELLO F. The segment anything model(SAM) for accelerating the smart farming revolution[J]. Smart Agricultural Technology, 2023, 6: 100367.
[57] LI Y, WANG D, YUAN C, et al. Enhancing agricultural image segmentation with an agricultural segment anything model adapter[J]. Sensors, 2023, 23(18): 7884.
[58] SHANKHDHAR G K, SHARMA R, DARBARI M. Sagro-lite: A light weight agent based semantic model for the internet of things for smart agriculture in developing countries[J]. Semantic IoT: Theory and Applications: Interoperability, Provenance and Beyond, 2021, 941: 265-302.
[59] HUANG Z, WANG X, HUANG L, et al. Ccnet: Criss-cross attention for semantic segmentation[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. New Jersey: IEEE, 2019: 603-612.
[60] 刘洁, 周典卓, 李燕, 等. 基于目标像素变化的柚果单目测距算法[J]. 农业工程学报, 2021, 37(19): 183-191.
LIU Jie, ZHOU Dianzhuo, LI Yan, et al. Monocular distance measurement algorithm for pomelo fruit based on target pixels change[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(19): 183-191. (in Chinese withEnglish abstract)
[61] ZHANG D, YU Y, LI C, et al. Mm-llms: Recent advances in multimodal large language models[EB/OL]. [2024-05-28]. https://doi.org/10.48550/arXiv.2401.13601.
[62] WEI J, BOSMA M, ZHAO V Y, et al. Finetuned language models are zero-shot learners[EB/OL]. [2022-02-08]. https://doi.org/10.48550/arXiv.2109.01652.
[63] DONG Q, LI L, DAI D, et al. A survey on in-context learning[EB/OL]. [2024-10-05]. https://doi.org/10.48550/arXiv.2301.00234.
[64] LIU H, LI C, WU Q, et al. Visual instruction tuning[J]. Advances in Neural Information Processing Systems, 2023, 36: 34892-34916.
[65] FERENTINOS KP. Deep learning models for plant disease detection and diagnosis[J]. Computers and Electronics in Agriculture, 2018, 145: 311-318.
[66] MA J, DU K, ZHENG F, et al. A recognition method for cucumber diseases using leaf symptom images based on deep convolutional neural network[J]. Computers and Electronics in Agriculture, 2018, 154: 18-24.
[67] SAVARY S, WILLOCQUET L, PETHYBRIDGE S J, et al. The global burden of pathogens and pests on major food crops[J]. Nature Ecology & Evolution, 2019, 3(3): 430-439.
[68] LIN F, CRAWFORD S, GUILLOT K, et al. MMST-ViT: Climate change-aware crop yield prediction via multi-modal spatial-temporal vision transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Piscataway, New Jersey: IEEE, 2023: 5774-5784.
[69] QING J, DENG X, LAN Y, et al. GPT-aided diagnosis on agricultural image based on a new light YOLOPC[J]. Computers and Electronics in Agriculture, 2023, 213: 108168.
[70] XIN L, DANIEL M, GEZA K, et al. Large language models are few-shot health learners[EB/OL]. [2023-05-24]. https://doi.org/10.48550/arXiv.2304.06136.
[71] YANG Y, XIANJIN F, XIANG L, et al. CDSG-SAM: A cross-domain self-generating prompt few-shot brain tumor segmentation pipeline based on SAM[J]. Biomedical Signal Processing and Control, 2019, 100: 106936.
[72] ERFAN S, SHAHARIAR G M, SARA A, et al. Misaligned roles, misplaced images: Structural input perturbations expose multimodal alignment blind spots[EB/OL]. [2025-04-01]. https://doi.org/10.48550/arXiv.2504.03735.
[73] FAN H, LIU X, FUH J Y H, et al. Embodied intelligence in manufacturing: Leveraging large language models for autonomous industrial robotics[J]. Journal of Intelligent Manufacturing, 2025, 36(2): 1141-1157.
[74] [E]HOEBERT T, LEPUSCHITZ W, VINCZE M, et al. Knowledge-driven framework for industrial robotic systems[J]. Journal of Intelligent Manufacturing, 2021, 34(2): 771-788.
[75] COLAS C, KARCH T, LAIR N, et al. Language as a cognitive tool to imagine goals in curiosity driven exploration[J]. Advances in Neural Information Processing Systems, 2021, 33: 3761-3774.
[76] CHIU H K, HACHIUMA R, WANG C Y, et al. V2v-llm: Vehicle-to-vehicle cooperative autonomous driving with multi-modal large language models[EB/OL]. [2025-02-14]. https://doi.org/10.48550/arXiv.2502.09980.
[77] 王文晟，谭宁，黄凯，等. 基于大模型的具身智能系统综述[J]. 自动化学报，2025，51(1)：1-19.
WANG Wensheng, TAN Ning, HUANG Kai, et al. Embodied intelligence systems based on large models: A survey[J]. Acta Automatica Sinica, 2025, 51(1): 1-19. (in Chinese with English abstract)
[78] LIN K, AGIA C, MIGIMATSU T, et al. Text2motion: From natural language instructions to feasible plans[J]. Autonomous Robots, 2023, 47(8): 1345-1365.
[79] DANNY D, FEI X, MEHDI S, et al. PaLM-E: An embodied multimodal language model[EB/OL]. [2023-03-06]. https://doi.org/10.48550/arXiv.2303.03378.
[80] WENLONG H, CHEN W, RUOHAN Z, et al. VoxPoser: Composable 3D value maps for robotic manipulation with language models[EB/OL]. [2023-11-02]. https://doi.org/10.48550/arXiv.2307.05973.
[81] WANG S. RoboFlamingo-Plus: Fusion of depth and RGB perception with vision-language models for enhanced robotic manipulation[EB/OL]. [2025-03-25]. https://doi.org/10.48550/arXiv.2503.19510.
[82] WANG Y J, ZHANG B, CHEN J, et al. Prompt a robot to walk with large language models[C]//2024 IEEE 63rd Conference on Decision and Control (CDC). Milan: IEEE, 2024: 1531-1538.
[83] MORCEGO B, YIN W, BOERSMA S, et al. Reinforcement learning versus model predictive control on greenhouse climate control[J]. Computers and Electronics in Agriculture, 2023, 215: 108372.
[84] LEE J, IM S, JEONG J S, et al. Learning hidden relationship

between environment and control variables for direct control of automated greenhouse using Transformer-based model[J]. Computers and Electronics in Agriculture, 2025, 235: 110335.

[85] ZHANG W, CAO X, YAO Y, et al. Robust model-based reinforcement learning for autonomous greenhouse control[C]//Asian Conference on Machine Learning. New York: PMLR, 2021: 1208-1223.

[86] BART V L, ELDERT J V H, SJOERD B. GreenLight-Gym: A reinforcement learning benchmark environment for greenhouse crop production control[EB/OL]. [2024-10-06]. https://doi.org/10.48550/arXiv.2410.05336.

[87] JIN Y, LIU J, XU Z, et al. Development status and trend of agricultural robot technology[J]. International Journal of Agricultural and Biological Engineering, 2021, 14(4): 1-19.

[88] YUAN Z, LIU K, PENG R, et al. PestGPT: Leveraging large language models and IoT for timely and customized recommendation generation in sustainable pest management[J]. IEEE Internet of Things Magazine, 2024, 8(1): 26-33.

Key technologies and development trends of intelligent decision-making large models for facility agriculture

FENG Zaiwen[1] , XU Duo[1,2,3] , TIAN Fang[1] , ZHANG Hongyu[1] , LI Wanli[1] , PENG Hui[1] , LIU Shanmei[1] , LIU Hanzun[1] , JIN Huidong[4] , HUANG Yuan[5] , WU Yingdan[6] , LONG Hao[1] , HAN Yiran[1,2,3]

(1. *College of Informatics*, *Huazhong Agricultural University*, *Wuhan* 430070, *China*; 2. *College of Plant Science and Technology*, *Huazhong Agricultural University*, *Wuhan* 430070, *China*; 3. *Digital Agriculture Research Institute*, *Huazhong Agricultural University*, *Wuhan* 430070, *China*; 4. *CSIRO Data61*, *Commonwealth Scientific and Industrial Research Organisation*, *Canberra ACT* 2601, *Australia*; 5. *College of Horticulture and Forestry Sciences*, *Huazhong Agricultural University*, *Wuhan* 430070, *China*; 6. *School of Science*, *Hubei University of Technology*, *Wuhan* 430068, *China*)

Abstract: Intelligent decision-making can be expected to improve protected agriculture, particularly in labor-intensive areas. Thereby, the productivity can be enhanced in facility agriculture. The intelligent decision-making technologies can also hold significant importance: One, the production efficiency and quality can be enhanced to ensure the supply, production, and income in the agricultural modernization; Another, the emerging technologies can be integrated into the precise environmental monitoring and personalized management. This research aims to focus on the multiple scenarios of the key application, such as the greenhouse environment control, modeling and prediction of the crop growth, pest and disease identification, as well as the crop phenotypic monitoring. The relevant emerging technologies were also introduced in the current protected agriculture. A systematic investigation was then made to determine the basic technologies of the visual, language, multi-modal, embodied intelligent, and large multi-agent models. The application potential of the existing large models was assessed in the key scenarios of protected agriculture. Large language models were generated from the agricultural data, providing suggestions and decision-making support to agricultural production. Crop models were established to predict the growth status of the crops in greenhouse environments. The decision-making of the large models was also utilized in the intelligent decision-making for protected agriculture. The intelligent perception of the crop semantic information was integrated with a large visual segmentation model in order to improve the accuracy and efficiency of the decision-making. The data reception, processing, feedback, and decision-making were selected in the greenhouse environment control for the protected agriculture. The physical environment was interacted to achieve the real-time environmental regulation. Embodied intelligence also emphasized that the agents were suitable for the complex environments in both the digital and physical worlds. The multi-modal data of the embodied intelligence depended mainly on the architecture training of the large model for the protected agriculture. A multi-agent large model consisted of multiple interactive AI agents that operated independently to make decisions and then take actions autonomously, according to the environmental changes. The entire production cycle of protected agriculture, data integration, and sharing was achieved after data integration. Multiple large model was collaborated and then interacted for the intelligent decision-making. The multi-model collaboration balanced the advantages of each model. The information mining and accurate analysis were conducted to improve the efficiency and quality of the agricultural production. In conclusion, the large model was improved with traditional protected agriculture, such as information perception, growth model construction, and precise decision-making. An intelligent decision-making system was constructed to promote protected agriculture. The crop growth and the environmental trends were more accurately evaluated after the processing of the multi-source heterogeneous data using large models. The finding can provide a scientific and precise decision-making basis for agricultural production. Intelligent decision-making was also the key driving force for agricultural development. The prosperous agriculture was promoted to fully explore the multi-source heterogeneous data, in order to unlock the potential value of data. An intelligent decision-making system was accelerated to construct for the various application scenarios of protected agriculture using large models. The finding can also provide scientific guidance to reduce the production costs for the high economic benefits.

Keywords: facility agriculture; embodied intelligence; multi-modal large models; large model based agents; intelligent decision-making